

Введение в анализ данных

Лекция 1 · 01.09.2026

1 Организационные вопросы

Устное пояснение: Лектор — Колоденкова А. Е., д. т. н., профессор кафедры ИСТ (информационных систем и технологий). В семестре читаются две дисциплины: «Статистический анализ данных» и «Методы оптимизации и исследование операций», по 16 лекций каждая.

Вся работа ведётся в Moodle: там выкладываются задания, тесты и контрольные точки. К обеим дисциплинам нужно подключиться в Moodle на первой неделе.

Действует балльно-рейтинговая система. По статистическому анализу данных — зачёт с оценкой:

- 70–75 баллов — «удовлетворительно» (3);
- 76–84 балла — «хорошо» (4);
- 85–100 баллов — «отлично» (5).

Баллы начисляются за тесты на лекциях, за лабораторные работы и за практики (тесты и выполнение самих работ). Доступ к пропущенным тестам открывается только по справке об уважительной причине.

Сегодняшняя лекция вводная: знакомство с дисциплиной, основные определения и примеры. С каждой из последующих лекций начинаются конкретные методы и математика. План: что такое данные, какие они бывают, какие бывают типы данных, разбор примеров.

2 Данные

2.1 Что такое данные

Определение 1 (Данные) . Данные — это совокупность фактов и отдельных фрагментов информации.

Устное пояснение: В разных источниках формулировка может отличаться, но смысл тот же: данные — это совокупность фактов, которые рассматриваются вместе.

Сами по себе данные ничего не значат: чтобы использовать их с пользой, важно провести анализ. В результате можно получить ценную информацию и на её основе принимать решения, осуществлять планирование и даже рассказать историю.

2.2 Способы представления: структурированные и неструктурированные

По способу представления есть два основных типа данных.

Структурированные организованные данные, собранные в таблицы или базы, например сведения о клиентах, их контактах и заказах. Их легко анализировать и обрабатывать.


Сюда же относятся сведения о студентах, заказах, графики.

Неструктурированные данные без чёткой структуры, представленные в различных форматах, например текстовые скриншоты с сайтов конкурентов и запись видеозвонка. Работать с ними довольно сложно.

Устное пояснение: В реальной жизни примерно в 95% случаев нас окружают именно неструктурированные данные. Значительная часть курса и последующих дисциплин посвящена методам и технологиям, которые позволяют такие данные структурировать.

3 Типы данных

3.1 Классификация данных



Слайд 1. Классификация данных по типу значений

По типу значений данные делятся на числовые и категориальные:

- **Числовые (количественные)** — выражены числами.
 - **Непрерывные** — неограниченное число вариантов (возраст, вес, давление).
 - **Дискретные** — ограниченное число вариантов (размер обуви, количество детей).
- **Категориальные (качественные)** — выражены словами.
 - **Порядковые** — имеют иерархию (выраженность боли, уровень настроения).

- **Номинальные** — не имеют иерархии (цвет глаз, порода собак, группа крови).

Определение 2 (Числовые (количественные) данные) . Числовые (количественные) данные представлены в виде чисел. Этот тип данных можно подсчитать, измерить и сравнить. Они позволяют ответить на такие вопросы, как «сколько», «как много», «как часто» и «как долго». Процесс сбора, анализа и интерпретации количественных данных называется **статистическим анализом**.

Примеры: скорость автомобиля, вес, рост детей и взрослых, размер обуви.

Определение 3 (Категориальные (качественные) данные) . Категориальные (качественные) — данные, выраженные не в числовом формате. Они представлены в виде изображений, видео, текстовых документов или аудио. Этот тип данных нельзя измерить или подсчитать. Они используются для определения отношения людей к чему-либо (это данные о чувствах, мотивах, мнениях, восприятии людей, а также о предвзятости). Качественные данные носят описательный характер и призваны ответить на вопросы «Почему?», «Как?» и «Что?». Они собираются в ходе наблюдений, опросов или интервью с пользователями.

Устное пояснение: На практике реальную информацию обрабатывают одновременно и как количественную, и как качественную. Для количественных данных применяется статистика (это наша дисциплина), а для качественных — методы и технологии искусственного интеллекта и алгоритмы машинного обучения (отдельная дисциплина на 4 курсе, через два семестра).

3.2 Пример: категориальные и количественные данные

Пример 1 (Слайд 4) . Определим, к какому виду относятся данные в таблице.

Отдел	Сотрудники	Подрядчики
ИТ	251	47
Отдел кадров	22	5
Продажи	25	178
Всего	298	230

- «ИТ», «Отдел кадров», «Продажи», «Всего» относятся к категории «Отдел». Это **категориальные данные**.
- «Сотрудники», «Подрядчики» относятся к категории, которую можно назвать «Типы работников». Это **категориальные данные**.
- Числа 251, 22, 25, 298, 47, 5, 178, 230 — **количественные данные**.

3.3 Вопросы о типах данных

Всегда ли числа являются количественными данными? Нет. Числа также могут представлять собой категориальные данные. Например, год: 2015, 2016, 2017. Другой пример — идентификатор сотрудника: 1000, 1012, 1016, 1090. Это категориальные переменные:

хотя они и представлены в виде чисел, на самом деле они что-то описывают и ничего не измеряют.

Всегда ли категориальные данные не являются числовыми? Нет — иногда категориальные данные могут быть представлены в виде чисел (см. пример выше).

Всегда ли количественные данные являются числовыми? Да.

Определение 4 (Простой способ определить количественную переменную) . Задать себе вопрос: имеет ли смысл складывать или вычитать числа? Если да, то переменная **количественная**, если нет — **категориальная**.

3.4 Числовые данные: дискретные и непрерывные

Определение 5 (Дискретные данные) . **Дискретные** — это целое число, которое нельзя разделить или разбить на отдельные части, дроби или десятичные числа (отдельные значения, которые обычно можно посчитать).

Пример: количество домашних животных у человека — может быть две собаки, но не две с половиной. Количество побед любимой команды болельщика — тоже дискретные данные: у команды не может быть половины победы (либо победа, либо поражение, либо ничья).

Определение 6 (Непрерывные данные) . **Непрерывные** — это значения, которые можно разделить на различные части, единицы, доли и десятичные дроби (например, могут принимать любое значение в пределах определённого диапазона).

Пример: рост и вес человека, температура воздуха — их можно измерить. Время тоже можно разделить (на полсекунды или полчаса). Обычно указывается диапазон: например, средний рост человека колеблется от 140 до 180 см.

Определение 7 (Как запомнить разницу) . Данные считаются **дискретными**, если их можно посчитать, и **непрерывными**, если их можно измерить.

3.5 Категориальные данные: номинальные, порядковые, булевые

Определение 8 (Номинальные данные) . **Номинальные** — самый простой тип, где каждая категория не имеет порядкового значения (помогают обозначать переменные, не имеющие количественных выражений). Для визуализации лучше всего использовать круговые и столбчатые диаграммы. Примеры: марки автомобилей или названия городов.

Определение 9 (Порядковые данные) . **Порядковые** — имеют определённую последовательность, часто от худшего к лучшему (сочетание числовых и категориальных сведений). Примеры: оценки качества («плохая», «средняя», «хорошая») или уровни образования («бакалавр», «магистр», «доцент»). Пример: рейтинги общепита, где 0 — самая низкая оценка, 5 — самая высокая. Для визуализации лучше использовать шкалы.

Определение 10 (Булевы данные) . Булевы — данные, которые могут принимать только два значения: True (истина) или False (ложь). Этот тип получил название в честь Джорджа Буля, английского математика, который разработал основы алгебры логики. Булевы данные помогают определить «да» или «нет». Например, у пациента либо есть диабет, либо нет; у соискателя на должность водителя либо есть права категории Б, либо нет. Бинарные качественные данные широко применяются в машинном обучении.

Устное пояснение: Булевый тип обычно рисуют сбоку от основной схемы типов данных или добавляют отдельным комментарием. Смысл: промежуточных состояний нет — нельзя быть «немного больным».

4 Анализ данных

4.1 Что такое анализ данных и зачем он нужен

Определение 11 (Анализ данных, Data analysis) . Анализ данных (Data analysis) — процесс сбора, очистки, преобразования и интерпретации данных для получения полезной информации и поддержки принятия обоснованных решений.

В результате можно находить закономерности и тренды, выявлять аномалии и составлять прогнозы. Полученные на основе данных выводы затем представляются в наглядном виде в форме диаграмм, графиков.

Кратко: мы собираем данные, очищаем их, преобразуем и интерпретируем, чтобы в итоге принять правильное, научно обоснованное решение. Анализируя прошлые ситуации и имея текущие данные, можно сделать взвешенный вывод о будущем.

4.2 Важность анализа данных

Анализ данных крайне важен, поскольку он превращает необработанную информацию в практические выводы.

1. **Принятие обоснованных решений:** анализируя прошлые и текущие данные, организации могут принимать более взвешенные решения, опираясь на факты, а не на предположения, опыт, интуицию.
2. **Бизнес-аналитика:** помогает компаниям понять предпочтения клиентов, тенденции рынка и области, требующие улучшения, чтобы опережать конкурентов.
3. **Оценка эффективности:** позволяет отслеживать, насколько хорошо работают процессы, продукты или стратегии, а также выявлять области, требующие улучшения.
4. **Управление рисками:** прогнозирует и снижает риски, выявляя потенциальные проблемы до того, как они усугубятся.

4.3 Процесс анализа данных

Процесс анализа данных состоит из шести этапов (в разных источниках их число может меняться в зависимости от степени детализации).

1. Определите цели.

2. Сбор данных.
3. Очистка и обработка данных.
4. Предварительный анализ данных.
5. Статистический анализ.
6. Визуализация и коммуникация.

4.3.1 Этапы 1–3

Определение 12 (

1. Определение проблемы, цели

) . Прежде чем приступать к анализу данных, важно чётко сформулировать вопрос, на который вы пытаетесь ответить (Какую проблему вы пытаетесь решить? Какова цель этого анализа данных? Что вы хотите получить в результате?), или проблему, которую вы хотите решить. Этот этап **задаёт** направление вашего анализа и позволяет сосредоточиться на релевантных данных и показателях.

Определите, что нужно для анализа, какие данные вам понадобятся, какие данные вы хотите отслеживать и измерять.

Примеры целей: определить уровень воды паводка; спрогнозировать курс валюты; спрогнозировать на будущее показатели, характеризующие электрооборудование.

Определение 13 (

2. Сбор исходных данных

) . Сбор данных может осуществляться из различных источников, таких как базы данных, опросы, датчики. Качественный сбор данных необходим для обеспечения точности и надёжности вашего анализа. Определите, какой тип данных вы хотите собрать: качественные (нечисловые, описательные) или количественные (числовые).

Сбор может быть не только количественным (эксперименты, базы данных, датчики с последующим сохранением в Excel), но и качественным: беседа с экспертами и операторами, которые делятся знаниями, а мы их записываем.

Определение 14 (

3. Очистка и обработка данных

) . Исходные данные редко бывают чистыми и упорядоченными. Они часто содержат ошибки, дубликаты или пропущенные значения, которые могут исказить результаты анализа. Очистка и систематизация данных включают в себя такие процессы, как удаление дубликатов, исправление ошибок и стандартизация форматов для обеспечения единообразия и точности.

Точность вашего итогового анализа будет зависеть от этого этапа.

Устное пояснение: Сырые данные (raw data) — «грязные»: дубликаты, пропуски, опечатки при ручном вводе. На практике и лабораторных работах будет видно, насколько сильно это влияет на результат применения методов, поэтому такие данные обязательно нужно выявить и убрать.

4.3.2 Этапы 4–6

Определение 15 (

4. Предварительный анализ данных

) . Когда у нас есть чистые и структурированные данные, приходит время провести анализ. Это может включать применение статистических методов, алгоритмов машинного обучения или других аналитических методов для выявления закономерностей, тенденций и аномалий.

Определение 16 (

5. Статистический анализ

) . Применять методы или модели для проверки идей, нахождения взаимосвязей и составления прогнозов.

Здесь смотрим, коррелируют ли полученные результаты с тем, что было ранее, и проводим проверку адекватности модели (подробнее — позже).

Определение 17 (

6. Визуализация

) . После завершения анализа необходимо интерпретировать результаты: осмыслить полученные данные, выявить ключевые моменты и сформулировать выводы, которые помогут ответить на исходный вопрос или решить проблему.

Наконец, важно эффективно представить результаты заинтересованным сторонам — создать визуализации, отчёты или презентации, отражающие сделанные выводы. Эффективная коммуникация гарантирует, что ваш анализ окажет значимое влияние на процесс принятия решений.

Устное пояснение: В этом же курсе на данной дисциплине работаем только с числами — значит, только со статистическим анализом (статистические методы). Алгоритмы машинного обучения и качественные данные — на следующий год.

4.4 Проблемы при анализе данных

Определение 18 (Итеративность процесса) . Процесс анализа данных — **итеративный**: может потребоваться возвращаться к предыдущим этапам по мере того, как вы получаете всё больше информации о своих данных.

Процесс может быть сложным, трудоёмким и проблематичным по ряду причин.

1. **Качество данных** — следует использовать только данные высокого качества. Если данные неточны или ненадёжны, выводы будут неполными или неточными.
2. **Объём данных** — количество доступных данных растёт в геометрической прогрессии, что затрудняет их сбор, хранение и анализ.
3. **Сложность данных** — данные могут быть сложны для понимания, что затрудняет выявление закономерностей и тенденций.

4. **Конфиденциальность данных** — анализ часто включает сбор и анализ персональных данных; их необходимо защищать.
5. **Безопасность данных** — конфиденциальные данные должны быть защищены от несанкционированного доступа и неправомерного использования. Как следствие, многие данные закрыты и их сложно найти.
6. **Нехватка квалифицированных специалистов** — найти квалифицированных специалистов непросто:
 - *дефицит кадров*: спрос на аналитиков данных превышает предложение рабочей силы;
 - *постоянное обучение*: специалистам нужно постоянно учиться и адаптироваться (хотя бы раз в 3–6 месяцев смотреть, что появилось нового);
 - *конкуренция за таланты*: организации конкурируют за лучших специалистов, что приводит к росту зарплат.
7. **Ограниченные ресурсы** — проекты могут потребовать значительных инвестиций:
 - *аппаратное и программное обеспечение*: часто требуются мощные вычислительные системы и специализированные инструменты;
 - *персонал*: наём и удержание специалистов может быть дорогостоящим;
 - *хранение данных*: для больших объёмов нужны надёжные и масштабируемые решения;
 - *обучение и развитие*: важно инвестировать в обучение сотрудников.
8. **Проблемы, связанные с искусственным интеллектом и машинным обучением** — несмотря на «революцию» последних лет, остаются сложности:
 - *интерпретируемость моделей*: понять, как модели ИИ приходят к своим выводам, может быть непросто;
 - *обеспечение надёжности моделей*: модели должны хорошо работать с новыми данными, а не выдавать неточные результаты;
 - *проблемы масштабируемости*: по мере роста объёма данных растут и требования к обработке.
9. **Идти в ногу со временем** — сфера постоянно развивается:
 - *новые технологии* (облачные вычисления, инструменты расширенной аналитики) требуют адаптации;
 - *развитие лучших практик*: методологии постоянно совершенствуются;
 - *сохранение конкурентоспособности*: нужно быть в курсе последних тенденций.

Устное пояснение: Классические статистические методы работают, когда исходных данных много. Для задач, где значений совсем мало (например, максимум пять), классические методы не подходят — тогда разрабатывают новые, например непараметрические методы.

По ИИ: нейронные сети получили мощное развитие за последние 7 лет и применяются повсеместно, хотя это лишь один из методов с большим количеством недостатков; часть учёных считает это модой. В основе ИИ и машинного обучения лежит сложная математика — подключение библиотеки скрывает мощный математический аппарат.

Часто приходится идти на компромисс: улучшая одно (например, масштаб), чем-то жертвуешь. Умение найти «золотую середину» ценно.

4.5 Рекомендации по преодолению трудностей

Несмотря на трудности, анализ данных — ценный инструмент, позволяющий получать информацию и принимать более взвешенные решения.

1. **Инвестируйте в качество данных:** не экономьте на качестве, убедитесь, что данные надёжны, безопасны с точки зрения конфиденциальности и точны.
2. **Используйте правильные инструменты (математический аппарат):** на рынке представлено множество инструментов, протестируйте их, прежде чем выбрать подходящий.
3. **Сотрудничайте с квалифицированными аналитиками данных:** работайте только с квалифицированными специалистами.
4. **Используйте статистику.**

4.6 Навыки, необходимые для анализа данных

1. **Хорошее знание математики и статистики.** Базовое понимание основ математики может оказаться очень полезным. Аналитики данных должны хорошо разбираться в статистике и теории вероятностей, чтобы выявлять закономерности и делать выводы.
2. **Знание SQL и реляционных баз данных.**

Определение 19 (Реляционная база данных) . Тип базы данных, в которой данные организованы в виде связанных таблиц, также называемых отношениями.

Определение 20 (SQL, Structured Query Language) . Язык структурированных запросов — язык, используемый для запросов к реляционным базам данных и взаимодействия с ними.

3. **Знание языка программирования.** Например, **Python** — язык общего назначения с синтаксисом, напоминающим английский, множеством пакетов и библиотек для работы с данными. Допустимы и другие языки (Java, C++).
4. **Знание Excel** — один из самых важных инструментов: хранение, структурирование и форматирование данных, вычисления, обобщение, выявление тенденций, сортировка, отчёты, диаграммы и графики.

Устное пояснение: Многие лабораторные работы выполняются в Excel: как выясняется на 4 курсе, студенты не знают многие встроенные функции и считают вручную то, что Excel считает автоматически.

5 Типы анализа данных

По-крупному существует четыре типа анализа данных: описательный, диагностический, прогностический и предписывающий.

5.1 Описательный анализ

Определение 21 (Описательный анализ, Descriptive Analysis) . Самый простой этап в процессе анализа данных. Цель — найти ответ на вопрос «**Что произошло?**». Направлен на обобщение исторических (ретроспективных) данных для понимания прошлых событий, тенденций, закономерностей. Даёт чёткое представление о том, что

произошло, с помощью отчётов, диаграмм и ключевых показателей. Используется для первоначального изучения набора данных.

Примеры методов:

- **Показатели частотного распределения** — измерение того, как часто каждое значение повторяется в наборе данных.
- **Показатели центральной тенденции** — нахождение среднего значения, медианы и моды путём анализа числовых значений в наборе данных.
- **Показатели вариативности** — измерение распределения точек данных в наборе. Используются четыре критерия: размах, межквартильный размах, стандартное отклонение и дисперсия.

5.2 Диагностический анализ

Определение 22 (Диагностический анализ, Diagnostic Analysis) . Собранные данные используются, чтобы понять причину возникшей проблемы и выявить причины, взаимосвязи, факторы, способствующие возникновению наблюдаемых закономерностей. Цель — ответить на вопрос «Почему это произошло?». По сути, это описательный анализ с небольшим участием машинного обучения. Особенно полезен для устранения неполадок и выявления факторов, влияющих на определённые результаты.

Примеры методов:

- **Анализ первопричин** — метод, направленный на выявление причин рассматриваемой ситуации.
- **Корреляционный анализ** — метод, применяемый к наборам данных с двумя или более значениями переменных; используется для понимания взаимосвязи и баланса между переменными.
- **Диаграмма Исикавы** — метод отображения причин с помощью простой наглядной схемы. Название — потому что схема напоминает скелет рыбы.

⋮) **Диагностический анализ (Diagnostic Analysis)**. Собранные данные используются для того, чтобы понять причину возникшей проблемы и выявить причины, взаимосвязи, факторы, способствующие возникновению наблюдаемых закономерностей. Его цель – ответить на вопрос: «**Почему это произошло?**». По сути, это описательный анализ с небольшим участием машинного обучения.

Диагностический анализ особенно **полезен** для устранения неполадок или выявления факторов, влияющих на определенные результаты.

Примеры методов:

- 1) **Анализ первопричин:** метод, направленный на выявление причин рассматриваемой ситуации.
- 2) **Корреляционный анализ:** метод, применяемый к наборам данных с двумя или более значениями переменных. Он используется для понимания взаимосвязи и баланса между переменными.
- 3) **Диаграмма Исикавы:** метод отображения причин с помощью простой наглядной схемы. Эта схема получила свое название, потому что напоминает скелет рыбы.

Слайд 2. Диаграмма Исикавы («рыбий скелет»): голова — проблема, «кости» — группы причин

5.3 Прогностический анализ

Определение 23 (Прогностический (предиктивный) анализ, Predictive Analysis) . Направлен на прогнозирование будущих тенденций, закономерностей, поведения или результатов на основе исторических данных. Предполагает создание статистических моделей или алгоритмов машинного обучения, которые могут с определённой степенью точности предсказывать будущие события, риски или закономерности. Цель — ответить на вопрос «**Что, скорее всего, произойдёт в будущем?**». Широко используется в финансах, маркетинге и здравоохранении.

Примеры методов:

- **Регрессионный анализ** — выявление взаимосвязи между зависимой и одной или несколькими независимыми переменными.
- **Деревья решений** — построение наглядных диаграмм, основанное на классификации: идеи объединяются в древовидную диаграмму, результаты прогнозирования указываются в ветвях.
- **Кластеризация** — разделение набора данных на сегменты для изучения его более естественным и простым способом.
- **Анализ временных рядов** — выявление взаимосвязи между данными, собранными через определённые промежутки времени.

3) **Прогностический анализ (предиктивный анализ, Predictive Analysis)**. Направлен на прогнозирование будущих тенденций, закономерностей, поведения или результатов на основе исторических данных. Он **предполагает** создание статистических моделей или алгоритмов машинного обучения, которые могут с определенной степенью точности предсказывать будущие события, риски или закономерности. Его цель — ответить на вопрос: «**Что, скорее всего, произойдет в будущем?**».

Широко используется в таких областях, как финансы, маркетинг и здравоохранение, для принятия взвешенных решений и планирования стратегий.

Примеры методов:

- 1) **Регрессионный анализ:** метод, используемый для выявления взаимосвязи между зависимой и одной или несколькими независимыми переменными.
- 2) **Деревья решений:** метод построения наглядных диаграмм, основанный на классификации. Идеи объединяются в древовидную диаграмму, а результаты прогнозирования указываются в ветвях в соответствии с этими идеями.
- 3) **Кластеризация:** метод, который позволяет разделить набор данных на сегменты и изучить его более естественным и простым способом.
- 4) **Анализ временных рядов:** метод, который используется для выявления взаимосвязи между данными, собранными через определенные промежутки времени.

Пример дерева решений

Кластеры

18

Слайд 3. Слева — пример дерева решений, справа — кластеризация

Устное пояснение: При работе со статистическими методами нельзя утверждать что-либо на 100% — 100% существует только в теории (в учебнике), в жизни его не бывает. Можно говорить лишь о том, что «скорее всего» произойдёт.

5.4 Предписывающий анализ

Определение 24 (Предписывающий анализ, Prescriptive analysis). Основывается на прогнозной аналитике и даёт рекомендации по дальнейшим действиям (собираются все данные, полученные на трёх предыдущих этапах, составляются рекомендации на будущее и план действий). Предлагает стратегии, различные сценарии и решения на основе данных для оптимизации процесса принятия решений. Цель — найти ответ на вопрос «**Что делать?**». Самый продвинутый и сложный вид анализа. Полезен для принятия решений и оптимизации процессов в сложных динамичных средах.

Примеры методов:

- **Моделирование** — анализ сложных наборов данных с помощью нелинейного и линейного программирования.
- **Алгоритмы машинного обучения** — предписывающие методы наиболее тесно связаны с ИИ: метод, при котором ИИ самостоятельно анализирует данные и возможные сценарии.

6 Методы анализа данных

Определение 25 (Статистические методы) . Предполагают применение математических принципов и подходов для анализа данных и формирования выводов о генеральной совокупности на основе выборочных данных. К таким методам относятся: регрессионный анализ, дисперсионный анализ, анализ временных рядов, факторный анализ, дискриминантный анализ, выборочная статистика и др.

Широко используются в экономике, социальных науках и здравоохранении для получения выводов на основе данных и составления прогнозов.

Определение 26 (Методы машинного обучения) . Позволяют компьютерам учиться на основе данных и делать прогнозы или принимать решения без явного программирования (кластерный анализ, классификационный анализ, метод главных компонент и др.).

Устное пояснение: На данной дисциплине изучаются только статистические методы. Методы машинного обучения (в т. ч. деревья решений, ансамблевые методы) — на следующий год, в дисциплине методов и технологий искусственного интеллекта, где работают и с количественными, и с качественными данными.

Устное пояснение: Далее (после перерыва) на слайдах рассматриваются шкалы измерения, визуализация данных, инструменты и сфера применения. Устного разбора этих разделов в записи лекции нет — материал приводится по слайдам.

7 Шкалы измерения

Определение 27 (Шкалы измерения) . Способы определения и классификации переменных. Используются для измерения качественных и количественных данных. Существует 4 типа шкал измерения.

7.1 Номинальная шкала

Определение 28 (Номинальная шкала) . Определяет свойство идентичности данных. Обладает определёнными характеристиками, но не имеет числового значения. Данные можно распределять по категориям, но их нельзя умножать, делить, складывать или вычитать друг из друга. Также невозможно измерить разницу между точками данных.

Единственный статистический анализ, который можно провести для номинальной шкалы, — подсчёт процентного соотношения или частоты; его можно представить графически с помощью гистограммы и круговой диаграммы.

Примеры: пол, страна рождения, тип продукта, цвет глаз.

Номинальные данные можно разделить на три категории:

- **с порядком** — можно разделить на подкатегории в порядке возрастания, например «холодно, тепло, жарко и очень жарко»;
- **без порядка** — например «мужчина» и «женщина»;
- **дихотомические** — имеют только две категории или уровня, например «да» и «нет».

7.2 Порядковая шкала

Определение 29 (Порядковая шкала) . Определяет данные, расположенные в определённом порядке. Несмотря на то что каждое значение ранжировано, нет информации о том, на чём категории отличаются друг от друга. Эти значения нельзя складывать или вычитать.

Предполагает ранжирование или упорядочивание атрибутов в зависимости от измеряемой переменной (в порядке возрастания или убывания). Измеряет степень проявления переменной.

Используется в маркетинговых исследованиях, рекламе и опросах об удовлетворённости клиентов («очень», «в значительной степени», «больше», «меньше»). Пример: показатели удовлетворённости, где «1» — «доволен», «2» — «нейтрально», «3» — «недоволен». Место в забеге тоже порядковый показатель: известен порядок финиша, но не то, насколько первый опередил второго.

7.3 Интервальная шкала

Определение 30 (Интервальная шкала) . Обладает свойствами номинальных и упорядоченных данных, но разница между точками данных может быть выражена количественно. Показывает как порядок переменных, так и точные различия между ними. Значения можно складывать или вычитать друг из друга, но нельзя умножать или делить.

- Например, 40 градусов — это не 20 градусов, умноженные на два.
- Ноль является существующей переменной: в порядковой шкале ноль означает отсутствие данных, а в интервальной ноль имеет значение (например, ноль градусов — это температура).
- Разница между точками данных одинакова: разница между 10 и 20 градусами такая же, как между 20 и 30 градусами.

Другие примеры: год выпуска автомобиля, месяцы года.

7.4 Шкала отношений

Определение 31 (Шкала отношений) . Включает свойства всех четырёх шкал измерения. Данные являются номинальными и определяются по идентичности, могут быть классифицированы по порядку, содержат интервалы и могут быть разбиты на точные значения. Данные в шкале отношений можно складывать, вычитать, делить и умножать.

Отличается от интервальной шкалы наличием **«истинного нуля»**: число ноль означает, что данные не имеют значения.

Примеры: вес, рост, расстояние. Человек не может быть ростом в ноль сантиметров или весить ноль килограммов, а также иметь отрицательный рост или вес.

8 Визуализация данных

Определение 32 (Визуализация данных) . Описывает методы, используемые для создания графического представления выборки данных. Помогает наглядно и эффективно представить данные. Цель процесса — максимально ясно донести результаты до аудитории. Графическое представление позволяет получателю информации понять закономерности и тенденции на основе набора данных, а также выявить различия между данными.

- **Гистограмма** — используется для представления числовых данных одной категории и их изменения с течением времени.
- **Линейчатая диаграмма** — используется для визуального представления тенденций и колебаний в наборе данных; часто используется для прогнозирования.
- **Круговая диаграмма** — используется для сравнения частей целого.

9 Инструменты анализа данных для исследований

1. **Microsoft Excel** — один из самых распространённых инструментов: базовые статистические функции, сводные таблицы, построение графиков; подходит для простых задач.
2. **R** — мощный язык программирования и среда для статистических вычислений и построения графиков; обширная коллекция пакетов; предпочтителен для сложных задач.
3. **Python** — универсальный язык с обширными библиотеками для анализа данных (NumPy, Pandas, scikit-learn); используется для очистки, предобработки, статистического анализа, машинного обучения и визуализации.
4. **SQL** — предметно-ориентированный язык для управления реляционными базами данных: запросы, извлечение данных, обработка данных.
5. **Tableau** — инструмент для визуализации данных: интерактивные и динамические информационные панели и отчёты.
6. **MATLAB** — язык высокого уровня и среда для численных вычислений и визуализации; применяется в инженерии, науке и финансах для анализа данных, моделирования и симуляции.

10 Сфера применения

1. **В бизнесе** — помогает понять поведение клиентов и оптимизировать услуги (розничные сети изучают покупки для персонализированных предложений и оптимизации запасов).
2. **В здравоохранении** — улучшает диагностику и позволяет разрабатывать персонализированные методы лечения; предсказание риска хронических заболеваний на основе истории и образа жизни.
3. **В науке** — помогает обнаруживать новые закономерности и инновации (анализ больших данных позволяет выявлять сигналы, указывающие на планеты за пределами Солнечной системы).

4. **Финансы** — выявляет мошенничество, оценивает риски, помогает принимать решения об инвестициях и бюджете.
5. **Маркетинг** — анализирует предпочтения клиентов, эффективность кампаний и рыночные тенденции для разработки целевых стратегий.
6. **Образование** — выявление «отстающих», анализ успеваемости и посещаемости, чтобы понять, кому нужна поддержка учителя.
7. **Наука об окружающей среде** — мониторинг состояния окружающей среды, прогнозирование стихийных бедствий, анализ спутниковых снимков и данных датчиков, моделирование последствий изменения климата.

Устное пояснение: Несмотря на девять перечисленных выше трудностей, анализ данных остаётся ценным инструментом, позволяющим принимать научно обоснованные решения — это будет видно на практиках и лабораторных занятиях.